


Предвиђање учинка играча у Fantasy Premier League-у

Сажетак

Циљ пројекта је предвиђање броја FPL поена које ће играч освојити у наредној утакмици и делимична репродукција резултата рада OpenFPL. Направљен је временски раздвојен pipeline без цурења информација: сезоне 2020/21–2023/24 користе се за обучавање, а сезона 2024/25 искључиво за тестирање. На главном prospective периоду, GW32–38, најбољи модел је XGBoost са MAE 0,944 и RMSE 1,842. Највећи проблем остају ретки велики повраћаји поена, које сви модели систематски потцењују.

Проблем и подаци

Јединица анализе је играч–утакмица, а циљна променљива `total_points`. Подаци су преузети из јавног `vaastav/Fantasy-Premier-League` (<https://github.com/vaastav/Fantasy-Premier-League>) репозиторијума. После одбацивања првих пет кола сваке сезоне, јер за њих не постоји довољна rolling историја, скуп садржи 94.164 train и 24.394 test реда. Главна евалуација обухвата 5.533 реда из GW32–38.



Расподела циљне променљиве

Расподела је изразито неуравнотежена: већина играча осваја мало или нимало поена, док су двоцифрени учинци ретки. Зато низак MAE сам по себи није довољан; нулти модел има MAE 1,084, али RMSE 2,469. Средња вредност циља је стабилна кроз сезоне (приближно 1,16 у train и 1,19 у test скупу), али се контекст клубова, играча и правила мења.

Припрема података и обележја

Rolling обележја рачунају се засебно по сезони и играчу и увек користе `shift(1)`. Тако исход текуће утакмице не може ући у њену предикцију. За `double gameweek` оба меча добијају исту `pre-GW` историју, док су домаћинство, противник и FDR везани за конкретан fixture.

Tier-2 скуп има 29 обележја:

- форму, минуте и ICT у последња 3/5 мечева;
- голове, асистенције, clean sheet, bonus, BPS и нападачке индексе;
- цену, проценат избора и позицију;
- јачину тима и противника, домаћинство и FDR;
- кумулативне сезонске поене и број одиграних мечева.

Недостајуће вредности попуњавају се медијаном наученом само на train скупу. Ознака GKP нормализована је у GK. Нова AM позиција постоји само у test сезони и изостављена је из главног поређења јер за њу нема train примера.

Модели и протокол


Поређени су модели растуће сложености:

- 1 константне нула и средња вредност;
- 2 просек поена у последњих пет мечева;
- 3 Tier-0: form_last_5 уз +1/0/-1 корекцију за лак/средњи/тежак FDR;
- 4 линеарна регресија;
- 5 Random Forest;
- 6 необтежени и тежински XGBoost;
- 7 засебни RF/XGBoost ансамбл по позицији.

Главни test је цела сезона 2024/25, а унапред дефинисан prospective пресек су GW32–38. Примарна метрика је RMSE, секундарне су MAE и R^2 . Додатно је урађен петоструки stable-club CV, где редови истог клуба не прелазе између train и validation дела.

Резултати

Модел	MAE	RMSE	R^2
XGBoost	0,944	1,842	0,315
Random Forest	0,976	1,846	0,312
Линеарна регресија	0,972	1,856	0,304
Last-5	0,997	2,008	0,186
Position RF+XGB	1,290	2,031	0,167
Tier-0 Form+FDR	1,291	2,075	0,130
XGBoost weighted	1,354	2,113	0,098
Средња вредност	1,447	2,227	-0,002
Нула	1,084	2,469	-0,231




Поређење модела

XGBoost је најбољи, али су RF и линеарна регресија врло близу. Тежински XGBoost и position ensemble су лошији, што показује да већа сложеност и агресивно наглашавање ретких учинака не гарантују бољу генерализацију. Stable-club CV за тежински модел даје RMSE 2,283 и представља строжи stress test за нове клупске контексте.

Поређење са OpenFPL радом

Категорија	Наш XGBoost RMSE	OpenFPL RMSE
Zeros	0,759	0,818
Blanks	1,396	1,291
Tickers	1,455	1,517
Haulers	5,397	5,142



Поређење по категоријама

Ово је делимична, а не идентична репродукција. OpenFPL користи и Understat, availability/expected-minutes обележја, више хоризоната, скалирање и већи ансамбл. Наш резултат је бољи за Zeros и Tickers, а слабији за Blanks и Haulers. Разлике се зато не могу приписати само алгоритму.

Анализа грешака

Највећи промашаји су углавном потцењени hauler-и. Примери су Mbeumo у GW33 (18 стварних, 4,73 предвиђена поена), Colwill у GW38 (15 према 1,80) и Ramsdale у GW32 (16 према 3,08). Голови, пенали, неочекивани clean sheet и bonus поени су ретки догађаји које лаговани табеларни подаци тешко предвиђају. По позицијама је најнижи RMSE за голмане (1,651), а највиши за нападаче (1,920).

Ограничења и даљи рад

Модел нема потпуне информације о повредама, суспензијама, очекиваним минутима, саставу и тржишним квотама. Није урађено вероватносно предвиђање, па једна бројчана прогноза не приказује неизвесност. Следећи кораци су rolling дообука за нову сезону, калибрисани prediction интервали, боља availability обележја и оптимизатор тима/трансфера.

Закључак

Пројекат показује да leakage-safe временска евалуација и јаке једноставне baseline вредности значе више од саме сложености модела. Необтежени XGBoost даје најбољи укупни резултат, али ретки велики учинци и даље ограничавају RMSE. Сви подаци, модели, метрике и графици могу се поново генерисати командама наведеним у README документу.

Литература

- 1 Daniel Groos, *OpenFPL — An Open-Source Forecasting Method Rivaling State-of-the-Art FPL Services*, arXiv:2508.09992, 2025.
- 2 Vaastav Anand, *Fantasy-Premier-League historical dataset*, GitHub репозиторијум.
- 3 Званични Fantasy Premier League API, подаци о играчима, клубовима и утакмицама.